#### **EMNLP 2020**

# Double Graph Based Reasoning for Document-level Relation Extraction

Paper: <a href="https://arxiv.org/pdf/2009.13752.pdf">https://arxiv.org/pdf/2009.13752.pdf</a>
Github: <a href="https://github.com/DreamInvoker/GAIN">https://github.com/DreamInvoker/GAIN</a>

#### Abstract

#### Document-level relation extraction

: sentence-level relation extraction 과는 달리, multiple sentence에서의 relation extraction

: 본 paper에서는 Graph Aggregation-and Inference Network (GAIN) featuring double graphs를 제안

→ 먼저, heterogeneous mention-level graph(hMG)를 구축하여 document내의 서로 다른 mention간의 relation을 modeling한다

→ Entity-level Graph(EG)를 구성하고, 이를 기반으로 entities간의 relation을 infer할 수 있는 새로운 mechanism을 제안한다.

: DocRED dataset에서 이전 SOTA보다 2.85 정도 향상된 F1 score

- Text에서 entities간의 semantic relation을 identify하는 task인 Relation Extraction(RE)는 QA와 같은 knowledge-based applications의 중요한 task
- Previous method들은
   single sentence에서 entities간의 relation을 extraction하는 "sentence level relation extraction"에 focus
   → 여러 sentence에 걸쳐 있는 entities간의 relation은 extract하지 못하는 한계
- 그래서, Document-level relation extraction task에 대한 다양한 시도가 있었음
  - → Firstly,
    relation을 가지는 subject entities와 object entities가 다른 sentence에 존재할 수 있기 때문에 sentence-level에서 처럼,
  - 각 sentence에 대해 relation을 정의할 수 없음
  - → Secondly,
    같은 entity가 여러 sentence에서 언급될 수 있기 때문에, entity를 잘 표현하기 위해서 cross-sentence context정보가 더해져야 함
  - → Thirdly,

    다양한 relation을 identify하기 위해서는 logical reasoning technique이 필요

#### **Elias Brown**

[1] Elias Brown (May 9, 1793– July 7, 1857) was a U.S. Representative from Maryland. [2] Born near Baltimore, Maryland, Brown attended the common schools. ... [7] He died near Baltimore, Maryland, and is interred in a private cemetery near Eldersburg, Maryland.

- 아래와 같은, Intra-sentence relations는 쉽게 recognize할 수 있다 (Maryland, country, U.S.), (Baltimore, located in the administrative territorial entity, Maryland), (Eldersburg, located in the administrative territorial entity, Maryland)
- 하지만 아래와 같은, 한 sentence에 있지 않고 long-distance dependencies를 가지는 경우 앞서 말한 logical reasoning이 필요 relations between Baltimore and U.S., relations between Eldersburg and U.S.

#### Elias Brown


[1] Elias Brown (May 9, 1793— July 7, 1857) was a U.S. Representative from Maryland. [2] Born near Baltimore, Maryland, Brown attended the common schools. ... [7] He died near Baltimore, Maryland, and is interred in a private cemetery near Eldersburg, Maryland.

- 아래와 같은, Intra-sentence relations는 쉽게 recognize할 수 있다 (Maryland, country, U.S.), (Baltimore, located in the administrative territorial entity, Maryland), (Eldersburg, located in the administrative territorial entity, Maryland)
- 하지만 아래와 같은, 한 sentence에 있지 않고 long-distance dependencies를 가지는 경우 앞서 말한 logical reasoning이 필요 *relations between Baltimore and U.S., relations between Eldersburg and U.S.*

(Maryland, country, U.S.)이고, (Eldersburg, located in the administrative territorial entity, Maryland)이니까, 이 둘을 이용하여 (Eldersburg, country, U.S.)로 reasoning할 수 있다.


- DocRED dataset을 사용
- Graph Aggregation-and Inference Network (GAIN) for document-level relation extraction 제안
  - GAIN은 (hMG)를 구축
  - 여기서, hMG는 2가지 type의 node와 3가지 타입의 edge로 구성되어 있다





- hMG로 document내의 서로 다른 mention간의 relation을 modeling
- hMG에 Graph Convolution Network(GCN)을 적용하여 각 mention에 대한 document-aware representation을 얻음
- hMG에서 같은 entity를 참조한 mention들을 합쳐서 Entity-level Graph(EG) 구축

위 과정을 통해 entities 간의 relation을 reasoning하는 새로운 path reasoning mechanism 제안



## Task formulation

- the task aims to extract the relations between different entities in  ${\cal E}$ 

$$\{(e_i, r_{ij}, e_j) | e_i, e_j \in \mathcal{E}, r_{ij} \in \mathcal{R}\}$$


$$\mathcal{E} = \{e_i\}_{i=1}^P$$

$$e_i = \{m_j\}_{j=1}^Q$$

 $m_j$  : span of words belonging to the j-th mention of the i-th entity

 ${\mathcal R}$  : a pre-defined relation type set.

- mainly consists of 4 modules
  - 1. Encoding module
  - 2. Mention-level graph Aggregation Module
  - 3. Entity-level Graph Inference Module
  - 4. Classification Module



#### 1. Encoding Module

 $\mathcal{D}=\{w_i\}_{i=1}^n$  인 document 의 각 단어에 대해 word embedding, entity type embedding, coreference embedding을 적용하고 각 embedding값을 concat

$$x_i = [E_w(w_i); E_t(t_i); E_c(c_i)]$$

이 벡터를 encoder에 넣어 context sensitive representation을 얻음

$$[g_1, g_2, \dots, g_n] = Encoder([x_1, x_2, \dots, x_n])$$

→ 이 때 이 encoder는 lstm과 같은 모델이 될 수 있다

2. Mention-level Graph Aggregation Module

: document-level information과 mentions와 entities 사이의 interactions를 modeling하기 위해 heterogeneous Mention-level Graph(hMG) 구축

mention node : 각 mention node는 entity에 대한 particular mention을 의미 nodes document node : 전제 document 정보를 modeling하기 위한 node → 1개

→ 다른 mention들과 interact하여 document안에서 mention들간의 long distance를 줄이는 역할 (Document node가 피봇일 때, mention node 간 거리에 최대 2이기 때문에)

### Intra-entity edge

: 동일한 entity를 언급하는 mention끼리 연결


Inter-entity edge

edges

: 서로 다른 entity에 대한 mention이 한 문장 내에 발생할 경우 연결

Document edge

: 문서 내 모든 mention과 해당 document node간 연결



2. Mention-level Graph Aggregation Module

: neighbor들의 feature들을 합치기 위해 hMG에 Graph Convolution Network(GCN)을 적용

: Given node u at the l-th layer, the graph convolutional operation can be defined as:

$$h_u^{(l+1)} = \underline{\sigma} \left( \sum_{k \in \mathcal{K}} \sum_{v \in \mathcal{N}_k(u)} W_k^{(l)} h_v^{(l)} + b_k^{(l)} \right) \qquad \qquad \mathcal{K} \text{ : different types of edges}$$
 
$$W_k^{(l)} \in \mathbb{R}^{d \times d}, b_k^{(l)} \in \mathbb{R}^d \rightarrow \text{Trainable param}$$
 
$$\mathcal{N}_k(u) \rightarrow \text{neighbors for node u connected in k-th type edge}$$

: GCN에서 서로 다른 layer는 서로 다른 level의 feature를 표현하므로, 각 node u에서 final representation을 표현하기 위해 각 layer에서 hidden states들을 concat한다.

$$\mathbf{m}_u = [h_u^{(0)}; h_u^{(1)}; \dots; h_u^{(N)}]$$

→ 이를 통해 neighbors로부터의 feature를 통합할 수 있고, 각 mention에 대한 representation을 얻을 수 있음

3. Entity-level Graph Inference Module

: 같은 entity를 언급하고 있는 mention은 하나의 entity node로 합쳐진다

: 여기서, document node는 고려하지 않음

: i-th entity node ei가 N번 mention됐다면, 아래와 같이 평균으로 ei를 표현한다.


$$\mathbf{e}_i = rac{1}{N} \sum_n \mathbf{m}_n$$

: inter-entity edge들을 EG내의 edge로


: EG에서 head entity와 tail entity간의 path는 중간에 거치는 through entity를 포함하여 아래와 같이 표현

 $\mathbf{p}_{h,t}^i = [\mathbf{e}_{ho}; \mathbf{e}_{ot}; \mathbf{e}_{to}; \mathbf{e}_{oh}]$  ightarrow [head와 through 간 edge, through와 tail 간 edge, tail과 through 간 edge, through와 head 간 edge]

: 많은 path중에서 어떤 path가 중요한지에 대해 attention을 이용하여 학습 (entity pair  $(\mathbf{e}_h,\mathbf{e}_t)$ 를 query로 하여서)



- 3. Entity-level Graph Inference Module
  - : 이 module을 통해
  - Multiple sentences에 퍼져있는 mention들의 정보를 잘 융합하여 entity를 나타낼 수 있다.
  - Attention mechanism을 통해 relation 예측 시 logical reasoning chains를 고려할 수 있다.



#### Classification Module

: task as multi-label classification task and predict relations between entities:

$$P(r|\mathbf{e}_h, \mathbf{e}_t) = sigmoid\left(W_b\sigma(W_a\underline{I_{h,t}} + b_a) + b_b\right)$$

$$I_{h,t} = [\mathbf{e}_h; \mathbf{e}_t; |\mathbf{e}_h - \mathbf{e}_t|; \underline{\mathbf{e}_h \odot \mathbf{e}_t}; \underline{\mathbf{m}_{doc}}; \underline{\mathbf{p}_{h,t}}]$$

head와 tail의 element-wise 곱 head와 tail간의 attention이 적용된 경로

: binary cross entropy 사용

$$\mathcal{L} = -\sum_{\mathcal{D} \in \mathcal{S}} \sum_{h \neq t} \sum_{r_i \in \mathcal{R}} \mathbb{I}(r_i = 1) \log P(r_i | \mathbf{e}_h, \mathbf{e}_t)$$
$$+ \mathbb{I}(r_i = 0) \log (1 - P(r_i | \mathbf{e}_h, \mathbf{e}_t))$$

# Experiments

#### Dateset

: DocRED(a large-scale human-annotated dataset for document-level RE constructed from Wikipedia and Wikidata.)

	Model	Dev				Test	
		Ign F1	Ign AUC	F1	AUC	Ign F1	<b>F1</b>
	CNN* (Yao et al., 2019)	41.58	36.85	43.45	39.39	40.33	42.26
	LSTM* (Yao et al., 2019)	48.44	46.62	50.68	49.48	47.71	50.07
	BiLSTM* (Yao et al., 2019)	48.87	47.61	50.94	50.26	48.78	51.06
	Context-Aware* (Yao et al., 2019)	48.94	47.22	51.09	50.17	48.40	50.70
	HIN-GloVe* (Tang et al., 2020)	51.06	-	52.95	-	51.15	53.30
graph-based	GAT <sup>‡</sup> (Velickovic et al., 2017)	45.17	-	51.44	-	47.36	49.51
	GCNN <sup>‡</sup> (Sahu et al., 2019)	46.22	-	51.52	-	49.59	51.62
	EoG <sup>‡</sup> (Christopoulou et al., 2019)	45.94	-	52.15	-	49.48	51.82
	AGGCN <sup>‡</sup> (Guo et al., 2019)	46.29	-	52.47	-	48.89	51.45
	LSR-GloVe* (Nan et al., 2020)	48.82	-	55.17	-	52.15	54.18
	GAIN-GloVe	53.05	52.57	55.29	55.44	52.66	55.08

# Experiments

#### - Dateset

: DocRED(a large-scale human-annotated dataset for document-level RE constructed from Wikipedia and Wikidata.)

BERT-RE $_{base}^*$ (Wang et al., 2019a)	-	-	54.16	-	-	53.20
RoBERTa-RE $_{base}^{\dagger}$ BERT-Two-Step $_{base}^{*}$ (Wang et al., 2019a)	53.85	48.27	56.05	51.35	53.52	55.77
BERT-Two-Step <sub>base</sub> (Wang et al., 2019a)	-	-	54.42	-	-	53.92
HIN-BERT $_{base}^*$ (Tang et al., 2020)	54.29	-	56.31	-	53.70	55.60
CorefBERT-RE* <sub>base</sub> (Ye et al., 2020)	55.32	-	57.51	-	54.54	56.96
LSR-BERT $_{base}^*$ (Nan et al., 2020)	52.43	-	59.00	-	56.97	59.05
$GAIN-BERT_{base}$	59.14	57.76	61.22	60.96	59.00	61.24
BERT-RE $^*_{large}$ (Ye et al., 2020)	56.67	-	58.83	-	56.47	58.69
CorefBERT-RE $_{large}^*$ (Ye et al., 2020)	56.73	-	58.88	-	56.48	58.70
RoBERTa-RE $_{large}^*$ (Ye et al., 2020)	57.14	-	59.22	-	57.51	59.62
CorefRoBERTa-RE $_{large}^*$ (Ye et al., 2020)	57.84	-	59.93	-	57.68	59.91
$\overline{ ext{GAIN-BERT}_{large}}$	60.87	61.79	63.09	64.75	60.31	62.76

## 참고 블로그

: <a href="https://kabbi159.medium.com/emnlp-2020-double-graph-based-reasoning-for-document-level-relation-extraction-%EB%85%BC%EB%AC%B8-%EC%A0%95%EB%A6%AC-7bb0dd5f65f3">https://kabbi159.medium.com/emnlp-2020-double-graph-based-reasoning-for-document-level-relation-extraction-%EB%85%BC%EB%AC%B8-%EC%A0%95%EB%A6%AC-7bb0dd5f65f3</a>